

저작권양도서 (Copyright Transfer Form)

소속 : 인하대학교 정보통신공학과

성명 : 홍인호

학번 : 12151641

논문제목 : 자세 인식을 이용한 온라인 시험에서의 의심 행동 감지

본인은 상기 논문을 2021학년도 1학기 정보통신프로젝트 최종 보고서 겸 결과 논문으로 제출하고자 합니다. 본 논문의 내용은 저자가 직접 연구한 결과인 것과 이전에 출판된 적이 없음을 확인합니다. 또한 공저자와 더불어 인하대학교 정보통신공학부에서 발간하는 논문집에 본 논문을 수록하는 것을 허락하며 제반 저작권을 정보통신공학부에 양도합니다.

2021 년 6 월 22 일

주저자 :

홍인호 

정보통신공학과장 귀하

자세 인식을 이용한 온라인 시험에서의 의심 행동 감지

Abnormal Behavior Detection in Online Exam Using Pose Estimation

홍인호
(Inho Hong)

요약: 2020년 코로나 이후 온라인 수업과 온라인 시험들이 전 세계적으로 많이 늘었다. 온라인 시험은 그 특성상 부정행위가 발생할 가능성이 오프라인 시험보다 매우 높다. 그에 따라 온라인 시험 중 의심 행동을 감지하는 연구들이 굉장히 많이 나왔다. 하지만 대부분의 연구들은 노트북에 기본적으로 탑재되어 있는 카메라나 간단한 웹캠을 이용하는 정면 얼굴 화면을 기준으로 하고 있다. 현대 사회에서는 스마트폰의 보급화로 인해 시험 중 옆모습을 촬영한 화면 또한 활용할 수 있으며, 몇몇 대학에서는 이 방식 또한 사용하고 있다. 본 논문은 옆모습 화면을 대상으로 하여 자세 인식을 이용한 온라인 시험 중 의심 행동 감지를 제안한다. 자세 인식을 위해 OpenPose를 사용하여 신체좌표를 프레임 별로 csv파일에 저장한 후 그 좌표 데이터를 학습시켜 프레임 단위 정상 상태와 의심 상태를 분류한다. 해당 모델은 93.5%의 정확도를 보였다. 그 후 2분 단위 영상을 해당 모델로 프레임 단위 정상 상태와 의심 상태를 판단한 다음, 그 데이터에서 특성을 추출하여 학습시켜 의심 행동을 한 영상과 정상 영상을 분류한다. 이 모델은 91.6%의 정확도를 보였다.

키워드: 자세 인식, 관절 정보, 온라인 시험, 의심 행동 감지, OpenPose

Abstract: Since the corona virus in 2020, online classes and online exams have increased significantly around the world. Due to the nature of the online exam, the possibility of cheating is much higher than that of the offline exam. As a result, many studies have been conducted to detect suspicious behavior during online exams. However, most of the studies are based on the front-face screen using the built-in camera or a simple webcam. In modern society, due to the spread of smartphones, a screen of a side profile during an exam can also be used, and some universities are using this method as well. In this paper, we propose the detection of suspicious behavior during an online exam using pose estimation by targeting a side profile screen. For pose estimation, OpenPose is used to store body coordinates for each frame in a csv file, and normal state and suspicious state is detected by learning the coordinate data to classify the frame-by-frame. This model shows an accuracy of 93.5%. After that, the 2 minutes video is used to determine the frame-by-frame normal state and the suspicious state, and then, by extracting and learning the characteristics from the data, the suspicious video and the normal video are classified. This model shows an accuracy of 91.6%.

Keywords: Pose Estimation, body keypoints, online exam, abnormal behavior detection, OpenPose

1. 서론

2020년 코로나 이후 온라인 수업과 온라인 시험이 많이 늘었다. 비대면으로 진행되는 온라인 시험은 코로나와 같은 위기 상황에 대면 시험보다 안전하다는 장점이 있지만, 그에 따른 단점도 많다. 온라인 시험은 그 특성상 부정행위가 발생할 가능성이 오프라인 시험보다 높다. 온라인 시험을 경험한 대학생들 역시 실시간 원격 화상시험의 단점으로 부정행위가 매우 우려된다는 응답을 한 바 있다 [1].

코로나는 전 세계적인 이슈였고, 외국에서도 많은 수의 대학들이 비대면 수업 및 시험을 진행하게 되면서 이에 따른 많은 연구들이 등장하였다. 얼굴 인식을 사용해 그 사람이 누구인지를 판단하거나 eye tracking 기술로 시선을 판단하는 방식[2]이

있었고, 대략적인 정면 얼굴 방향과 사용자의 마우스 움직임을 함께 분석하는 방식[3] 등 여러 가지 연구들이 존재한다. 하지만 이러한 연구들은 대부분이 얼굴 정면 화면을 기준으로 하고 있다. 현대 사회에서는 스마트폰의 보급화로 인해 온라인 시험 중 옆모습을 촬영하는 화면 또한 충분히 활용할 수 있으며, 몇몇 대학에서는 이 방식을 사용하고 있다. 정면이 아닌 화면을 대상으로 하는 연구도 있었지만, 이미지 픽셀 분석 방식이기 때문에 여러 가지 제약조건들이 존재했다[4]. 이에 본 논문은 얼굴 정면 화면이 아닌 옆모습 화면을 대상으로 한 온라인 시험 중 의심 행동 감지 방식을 제안한다.

본 연구는 실시간 Multi-Person 2D Pose Estimation 기술인 OpenPose를 기반으로 한다[5].

II. 관련 연구

1. 온라인 시험 중 부정행위 감지

온라인 시험 중 부정행위를 감지하기 위한 프로그램은 여러 가지가 존재한다. "Video Interpretation for Cost-Effective Remote Proctoring to Prevent Cheating." [2]의 경우 얼굴 인식을 이용한 사람 판별, 여러 명의 사람을 감지, 자리 비움, 금지된 물건 발견, 시선 트래킹 등의 방법을 이용한다. "Automated Online Exam Proctoring" [4]은 두 개의 카메라를 이용하여 훨씬 더 정밀한 시선 추적 기술을 제안한다. "A Visual Analytics Approach to Facilitate the Proctoring of Online Exams" [3]은 정면 얼굴 화면의 대략적인 시선 판단과 함께 사용자의 마우스 움직임을 분석하여 종합적인 결과를 내는 방법을 제안한다. 이외에도 지문 인식을 추가하는 등 [12] 굉장히 많은 연구들이 있지만, 대부분이 얼굴 정면 화면을 대상으로 하고 있다.

2. Pose Estimation

옆모습 화면의 경우 얼굴 인식 기술이 제대로 동작하기 어렵고, 얼굴 인식 기술로 얻어낼 수 있는 것들 외의 정보도 많이 존재한다. 따라서 자세 인식 기술을 활용하는 것이 적합하다고 할 수 있다.

자세 인식 기술은 Top-down 방식과 Bottom-up 방식으로 나뉜다. Top-down 방식은 정확도가 높은 대신 Crop 과정이 필요하고, 비교적 느리다. 그에 비해 Bottom-up은 정확도가 비교적 낮은 대신 속도가 빠르다. 선택한 옆모습 화면 환경이 사람이 너무 작게 나오거나 학습되기 힘든 특수한 자세를 취하는 것이 아니기 때문에 정확도보다는 속도에 초점을 맞춰 Bottom-up 방식을 선택하였다.

Bottom-up 방식은 Associate Embedding, PersonLab, MultiPoseNet, METU, TFMAN, OpenPose 등 여러 가지 방법이 존재한다 [5][6]. 이 중 OpenPose가 다양한 환경에서도 사용이 가능하고, 최근까지도 업데이트를 통해 성능을 개선하고 있기에 선택하였다.

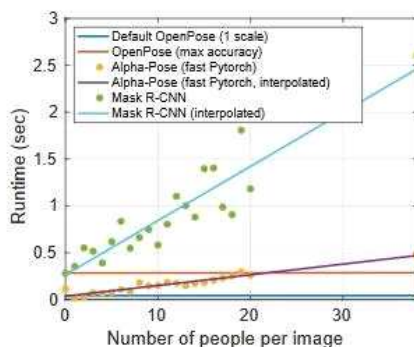


그림 1. OpenPose 성능 비교

3. OpenPose

OpenPose는 단일 이미지에서 사람들에 대해 신체 부위의 keypoints를 감지하는 시스템이다. 여러 단계의 CNN 네트워크 구조를 갖고 있고, 일반 CPU 환경, CUDA 환경, OpenCL 환경, python, C++ 등 다양한 환경에서도 제한 없이 사용할 수 있도록 설계되었다.

OpenPose의 전체적인 흐름은 그림 2와 같이 이

루어진다. 이미지에서 Part Affinity Fields(PAFs)와 Part Confidence Maps(confidence map)를 검출하여 사람의 관절인 특징점을 찾은 후, 추출한 관절의 관계성을 추정하여 매칭한다. 그림 3에서 파란색 부분이 PAFs를 추출하는 부분이고, 붉은색 부분이 Confidence Map을 추출하는 부분이다.

VGG 네트워크를 이용하여 feature F를 추출하고, 그것을 입력값으로 사용하여 convolution 연산을 통해 PAFs를 추출한다. PAFs는 여러 번의 단계를 거쳐 점차 개선되는 방식이 사용된다. 최종적으로 구해진 PAFs는 원래의 F값과 더해져 Confidence Map을 구하는 과정으로 넘어가게 된다. Confidence Map 역시 PAFs와 같이 여러 번의 단계를 거쳐 최종적인 결과가 도출된다. 2019년 이전 OpenPose의 구조는 그림 3과는 달리 모델 구조가 병렬로 연결되어 있었다. 하지만 2019년 이후 그림 3과 같이 직렬로 변경함으로써 메모리에서 이득을 취하여 속도가 향상되었고, PAFs 이후 confidence map을 구하게 되어 정확도 또한 향상되는 결과를 얻었다.




그림 2. OpenPose 전체 흐름도




그림 3. OpenPose multi-stage CNN 구조

OpenPose에서 사용하는 신체 관절 keypoints는 Body_25_model로 그림 4와 같다.




그림 4. Body_25_model (25 parts)

0-7, 15-18의 keypoints들이 상체 부분이 되는데, 여기서 0, 15-18의 얼굴 keypoints를 사용한다. 각 관절을 선택한 이유는 본문에 설명되어 있다.

4. Neural Network




그림 5. Neural Network 구성 예시

인공 신경망(Artificial Neural Network)은 기계학습과 인지과학에서 생물학의 신경망에서 영감을 얻은 통계학적 학습 알고리즘이다. 인공 신경망은 시냅스의 결합으로 네트워크를 형성한 인공 뉴런이 학습을 통해 시냅스의 결합 세기를 변화시켜, 문제 해결 능력을 가지는 모델 전반을 가리킨다. 인공 신경망 모델은 특성과 레이블 사이의 복잡한 관계를 찾을 수 있다. 신경망은 하나 이상의 은닉층으로 구성된 그래프를 뜻한다. 본 논문에서는 머신러닝 모델로 Neural Network를 선택하였는데, 그 이유는 본론에 설명되어 있다.

III. 본론

OpenPose를 이용하여 특정 영상의 프레임별 keypoints를 csv파일 형태로 저장할 수 있다. 해당 프레임을 정상 상태와 의심 상태로 분류하고, 지도 학습을 진행하였다. 이것이 프레임 분류 모델이다. 그 후 2분 단위의 영상을 부정행위를 한 영상과 하지 않은 영상으로 분류하고 프레임 분류 모델로 분석하여 추출한 특성들을 바탕으로 지도 학습을 진행하였다. 이것이 두 번째 모델인 영상 분류 모델이다. 학습시키는 과정에서 최적의 학습 모델을 찾기 위해 여러 가지 모델에 대해 실험하였다. 전체적인 진행도는 그림 6과 같다.

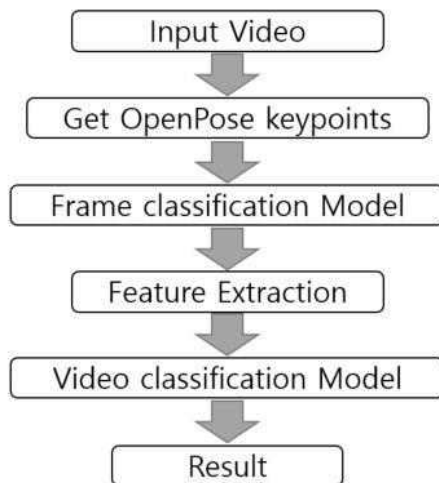


그림 6. 전체 시스템 구성도

1. 프레임 분류 모델

1.1. 데이터 구성

‘시험을 보는 옆모습 화면’ 데이터는 인터넷과 같이 공개된 곳에서 구하기가 매우 어렵다. 따라서 필요한 데이터를 자체적으로 제작하였다. 초당 20~30프레임, 30초 길이의 영상 100개를 직접 촬영하여 약 80000개의 프레임에 대해서 OpenPose를 이용하여 (x, y) 좌표값을 추출하였고, 해당 좌표값들을 csv파일로 저장하였다. 지도 학습을 위해 정상 상태는 0, 의심 상태는 1로 설정하여 프레임 단위로 함께 출력하도록 하였다. train과 test 비율은 8:2로 설정하였는데, 약 16000개의 데이터가 테스트에는 충분한 양이기 때문에 train 비율을 비교적 높였다.

영상을 자체적으로 촬영할 때, 다양한 환경에서 촬영하기 위해 카메라의 위치(좌, 우), 데스크탑/노트북 여부, 모니터의 크기(24, 27, 32인치), 의자와 책상의 높낮이(앉은키) 등을 변화시켜가며 촬영하였다.



그림 7. 데이터 촬영 예시

1.2. 데이터 학습

숫자 좌표값을 이용한 지도 학습 방식으로 진행할 때, 추천되는 여러 가지 머신러닝 알고리즘에 대해 실험하였다. 이 때, 그림 3에 있는 Body_25_Model의 상체의 모든 keypoints들을 활용하는 것이 아니라, 0과 15-18, 즉 얼굴 부분의 keypoints들을 사용하는 것으로 결정하였다. 그 이유는 그림 8과 같은 화면을 포함하기 위함이다. 상체 keypoints들을 전부 사용하여 학습했을 경우, 모든 머신러닝 알고리즘에서 그림 8처럼 상체가 거의 나오지 않는 화면을 무작정 의심 상태로 분류하는 것을 확인하였다. 반면 얼굴 부분의 keypoints들을 사용하여 학습한 모델은 해당 상황에서도 올바르게 분류하는 것을 확인하였다.




그림 8. 상체가 거의 나오지 않는 화면 예시

총 5개의 머신러닝 모델에 대해 실험하였다. 이 중 테스트 정확도는 앞서 8:2로 구성한 다른 환경의 테스트 세트에 대한 정확도를 의미한다.

표 1. 머신 러닝 알고리즘 실험 결과

	학습 정확도	테스트 정확도
Logistic Regression	89.54%	72.52%
SVM	94.05%	50.39%
Decision Tree	99.48%	87.79%
Random Forest	99.63%	87.49%
Neural Network	94.88%	93.82%

TensorFlow와 Scikit-learn, Keras의 패키지를 이용하였다. Logistic Regression의 경우 기본 학습 데이터 세트 정확도가 낮았고, SVM, Decision Tree, Random Forest의 경우 학습 정확도는 높지만 별도로 구성된 테스트 데이터 세트에서는 정확도가 90%미만이었다. 과대적합과 같은 문제가 발생한 것으로 추정된다. 이 중 Neural Network 방식이 학습 정확도와 테스트 정확도 모두 90%이상의 결과가 나타났기 때문에 Neural Network 방식을 선택하였다.

1.3. 파라미터 설정

최적의 하이퍼파라미터들의 설정을 위해 검증된 Scikit-learn의 gridsearchCV패키지를 이용하여 그리드 탐색을 진행하였다. 1~5계층, 1~500노드, 10~200의 batch_size, 1~50 epoch에 대해 진행하였다. 2계층, 30노드, 80 batch_size, 5 epoch의 경우가 가장 성능 평가가 좋다는 것을 확인하였다.

표2. 설정된 파라미터

Layer	2
Node	30
Epoch	5
Batch size	80

1.4. Test 결과

그리드 탐색 후 설정한 하이퍼파라미터들의 값을 설정한 후 학습한 결과 학습 정확도는 95.27%를 보였다. 약 16000개의 프레임에 대한 테스트 결과 정확도는 약 93.5%로 표3과 같다.

표3. 테스트 세트 결과

	Predicted NO	Predicted Yes
Actual NO	7332	634
Actual Yes	401	7564

2. 영상 분류 모델

2.1. 데이터 구성

시험 중 부정행위 행동은 긴 시간에 걸쳐 서서히 일어나는 것보다는 특정 시험 문제를 발견하거나 막혔을 때 1분에서 2분 사이에 빠르게 발생하는 경우가 대부분이다. 따라서 2분 길이의 영상을 환경으로 설정하고, 부정행위를 한 영상과 하지 않은 영상으로 구분한 다음 OpenPose로 좌표값을 추출한 데이터를 이용하여 앞서 구성한 분류 모델로 의심

상태와 정상 상태를 프레임 단위로 분류한 데이터를 얻을 수 있다.

프레임 단위로 분류된 데이터에서 총 7개의 특성을 추출하였다. (1)의심 상태 수, (2)의심 상태 변화 횟수, (3)최대 의심 상태 시간, (4)최대 정상 상태 시간, (5)2초 이상 의심 상태 횟수, (6)5초 이상 의심 상태 횟수, (7)10초 이상 정상 상태 횟수로 7개이다. 초당 20~30프레임 영상에 적용하였으므로, 해당 영상들은 2400~3600프레임으로 구성된다. 해당 프레임 비율에 맞춰서 추출한 특성을 csv파일로 저장하였다.

표4. 추출한 특성의 번호와 의미

특성 번호	특성의 의미
(1)	의심 상태 프레임의 수
(2)	정상 프레임에서 의심 상태 프레임으로의 변화 횟수
(3)	연속된 의심 상태 프레임 중 최대 길이
(4)	연속된 정상 상태 프레임 중 최대 길이
(5)	의심 프레임이 2초 이상 연속된 횟수
(6)	의심 프레임이 5초 이상 연속된 횟수
(7)	정상 프레임이 10초 이상 연속된 횟수

전체적으로 분석했을 때, 의심 상태 시간과 의심 상태 변화 횟수만으로도 정확도 80%이상의 분류가 가능하다는 것을 확인할 수 있었다. 하지만 작은 움직임도 포함하여 더 정확한 분류를 위해 다시 한 번 머신 러닝을 적용하는 것을 선택하였다.

2분 길이의 영상 100개를 학습에 사용하였고, 테스트 데이터로는 2분 이상의 영상 60개를 사용하였다. 부정행위 영상의 경우 자리를 비우거나, 다른 사람과 대화하거나, 벽에 붙여놓은 종이를 보는 등의 움직임이 있고, 정상 영상의 경우 간단한 스트레칭 정도의 움직임을 포함하여 정직하게 화면을 보도록 하였다. 환경을 바뀌가며 영상을 자체적으로 촬영하는 것이 쉽지 않아 데이터의 양이 부족하기에, 테스트 데이터의 비중을 늘리는 선택을 하였다.

2.2. 데이터 학습

특성의 수가 비교적 적은 편이기 때문에 특성 표준화 후 Scikit-learn의 Polynomial Feature 패키지를 이용하여 특성을 2차 다항식으로 변환해 총 36개의 특성으로 확장하였다. 그 후 Scikit-learn의 SelectFromModel 패키지를 이용하여 특성 중요도를 판단하고, 너무 낮은 중요도(0.0025 미만)를 가진 특성들을 제외하여 총 27개의 특성을 선택하였다. 제외된 특성들의 의미는 표5에 설명되어 있다. 표5에서 (1)~(7)은 표4에서 설정한 특성 번호에 해당한다. 그 후 앞선 모델과 마찬가지로 5개의 머신 러닝 모델에 대해 실험하였다.

표5. 제외된 특성. (1)~(7)은 표4의 특성을 의미

제외된 특성	해당 특성의 의미	중요도
1	1(상수)	0
2	$(1) \times (2)$	0.0013
3	$(1) \times (6)$	0.0021
4	$(2) \times (6)$	0.0017
5	$(2) \times (7)$	0.0018
6	$(3) \times (6)$	0.0012
7	$(5) \times (6)$	0.0020
8	$(6)^2$	0.0004
9	$(6) \times (7)$	0

표6. 두 번째 머신 러닝 알고리즘 실험 결과

	학습 정확도
Logistic Regression	84%
SVM	79%
Decision Tree	75%
Random Forest	87%
Neural Network	92%

두 번째 모델의 학습 데이터 세트는 모두 다른 환경에서 촬영된 영상이기 때문에 학습 정확도만으로 판단하였다. 유일하게 Neural Network만이 90% 이상의 정확도를 보였기 때문에 선택하였다.

2.3. 파라미터 설정

첫 번째 모델과 마찬가지로 Scikit-learn의 gridsearchCV를 이용하여 다시 파라미터값을 설정하였다.

표7. 설정된 두 번째 모델 파라미터

Layer	2
Node	50
Epoch	50
Batch size	20

2.4. 테스트 결과

시험 시간은 당연히 2분 이상이기 때문에 2분 이상 길이의 영상에 적용하기 위해 연속적인 모든 2분 구간에 대해 확인하는 방식을 사용하였다. 실시간 영상의 경우 OpenPose를 사용하여 해당 영상의 초당 프레임을 알 수 있고, 이미 저장된 영상 파일을 이용하는 경우에는 기본 파일 속성에서 해당 영상의 초당 프레임을 알 수 있다. 그에 맞춰 2분에 해당하는 프레임 수를 설정한 후 2분 이상의 길이를 가진 영상 60개에 대해 테스트하였다. 테스트 결과 정확도는 약 91.67%로 표8과 같다.

표8. 두 번째 모델 테스트 결과

	Predicted NO	Predicted Yes
Actual NO	26	4
Actual Yes	1	29

IV. 결론

통상적으로 온라인 시험 중 의심 행동을 판단하는 시스템들은 대부분 얼굴 정면 화면을 기준으로 한다. 스마트폰이 보급화된 현대 사회에서는 많은 수의 대학생들이 스마트폰을 가지고 있기 때문에 책상 옆에서 촬영하는 옆모습 화면 또한 활용할 수 있다. 본 논문에서는 옆모습 화면을 대상으로 온라인 시험 중 의심 행동을 판단하는 모델을 제안한다. 제안된 모델은 분류를 위해 동영상 파일이 아닌 숫자 데이터 csv파일을 사용하여 학습했기 때문에 빠르게 학습 및 분류가 가능하다. 프레임 단위 의심 자세 분류 모델은 약 93.5%의 결과를 보였으며, 의심 영상 분류 모델은 약 91.6%의 결과를 보였다.

본 논문에서 제안되는 시스템은 옆모습 환경에 대한 전체적인 keypoints를 활용하는 방식으로, eye tracking 방식처럼 아주 미세한 움직임까지 감지하는 것이 아니기 때문에 치밀하게 계획된 부정행위는 감지하기 어렵다는 한계를 가진다. 이것은 [3][12]에서 적용된 것과 같이, 마우스 움직임 감지나 정면 얼굴 화면 감지와 함께 사용할 수 있다면 해결될 수 있으리라 기대한다.

V. 참고문헌

- [1] Kim Misook, Lee Dong Ju. "University students' perceptions on the practices of online learning in the COVID-19 situation and future directions." Multimedia-Assisted Language Learning, 23(3), 359-377. 2020.
- [2] Kiran P.Kamble, Vijay R.Ghorpade. "Video Interpretation for Cost-Effective Remote Proctoring to Prevent Cheating.". Proceeding of First Doctoral Symposium on Natural Computing Research 2021; 169:259-269. 2021.
- [3] Haotian Li, Min Xu, Yong Wang, Huan Wei, Huamin Qu. "A Visual Analytics Approach to Facilitate the Proctoring of Online Exams". Accepted at CHI2021. 2021
- [4] Khatereh Jalali, Fakhoroddin Noorbehbahani. "An Automatic Method for Cheating Detection in Online Exams by Processing the Student's Webcam Images.". 3rd Cpmference on Electrical and Computer Engineering Technology. 2017
- [5] Zhe Cao, Gines Hidalgo, Tomas Simon, Shih-En Wei, Yaser Sheikh. "OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields.". IEEE Transactions on Pattern Analysis and Machine Intelligence. 2019
- [6] Ke Sun, Bin Xia, Dong Liu, Jingond Wang. "Deep High-Resolution Representation Learning

- for Human Pose Estimation.". CVF Conference on Computer Vision and Pattern Recognition(CVPR). 2019
- [7] Martin Abadi, Ashish Agarwal et al, "Tensorflow: Large-scale machine learning on heterogeneous systems." Software available from tensorflow.org. 2015
- [8] Fabian Pedregosa, Gael Varoquaux, Alexandre Gramfort, Vincent Michel. "Scikit-learn: Machine Learning in Python.". Journal of Machine Learning Research 12. 2012
- [9] Chollet, Francois and others. "Keras". <https://keras.io>. 2015
- [10] Kim, K.S. "Real-time Online Test Experience and Fairness at a University.". Journal of the Korea Academia-Industrial cooperation Society, 21(9), pp 229-237. 2020
- [11] PEW RESEARCH CENTER, Spring 2018 Global Attitude Survey. 2018
- [12] Razan Bawarith, Abdullah Basuhail, Anas Fattouh, Shehab Gamalel-Din. "E-exam Cheating Detection System.". International Journal of Advanced Computer Science and Applications(IJACSA) 8(4). 2017



홍인호

2015년 ~ 현재 인하대학교 정보
통신공학과 학사 과정 재학 중
2021년 8월 졸업 예정
관심분야는 알고리즘, 딥러닝, 소
프트웨어 개발